

Daniel Oliveira da Silva
Gustavo Gama Cardozo
Luendison Costa Dos Santos Alves

PROJETO DE PESQUISA
DESENVOLVIMENTO DE UM CHATBOT BASEADO EM RAG PARA CONSULTA
FUNDAMENTADA E RASTREÁVEL AO CÓDIGO DE DEFESA DO CONSUMIDOR
(CDC), COM ANÁLISE COMPARATIVA AO MESMO MODELO DE LINGUAGEM
GENERATIVO UTILIZADO SEM MECANISMO DE RECUPERAÇÃO

Projeto de Pesquisa apresentado ao Programa de Capacitação e Formação do Centro de Competências Embrapii em Tecnologias Imersivas (AKCIT) como parte dos requisitos para elaboração do Trabalho de Conclusão de Curso.

GOIÂNIA
2026

SUMÁRIO

1 INTRODUÇÃO	3
2 PERGUNTA DE PESQUISA	3
3 HIPÓTESE (se aplicável)	4
4 JUSTIFICATIVA	4
5 OBJETIVO GERAL	5
5.1 Objetivos específicos (se aplicável)	5
6 MÉTODO PRELIMINAR	6
7 RESULTADOS ESPERADOS	7
8 CRONOGRAMA DAS ATIVIDADES	8
REFERÊNCIAS	9

1 INTRODUÇÃO

O avanço dos Modelos de Linguagem de Grande Escala (*LLMs*, do inglês *Large Language Models*) tornou acessível a consulta de informações complexas por meio de linguagem natural, incluindo questões de natureza jurídica. No entanto, esses modelos apresentam uma limitação crítica denominada alucinação, definida como a geração de conteúdo textualmente coerente, mas factualmente incorreto ou sem fundamentação nas fontes existentes. Dahl et al. (2024) conduziram o primeiro estudo sistemático de alucinações jurídicas em *LLMs* de acesso público e demonstraram que modelos como o *ChatGPT 4* alucinam em pelo menos 58% das consultas sobre casos judiciais reais, frequentemente aceitando como verdadeiras premissas incorretas fornecidas pelo usuário. Esse comportamento representa risco relevante no contexto do Direito, pois respostas falsas com aparência de autoridade podem induzir tanto profissionais quanto cidadãos a erros de consequências graves — fenômeno já registrado no Brasil com caso documentado de advogado que apresentou jurisprudências e doutrinas geradas por IA sem fundamentação real em recurso ao Tribunal de Justiça de Santa Catarina (CONSULTOR JURÍDICO, 2025).

No contexto do direito do consumidor brasileiro, o Código de Defesa do Consumidor (CDC), instituído pela Lei n.º 8.078/1990, representa o principal instrumento legal de proteção ao consumidor no país (BRASIL, 1990). Por se tratar de um corpus textual delimitado, público e de conteúdo verificável, o CDC oferece condições favoráveis para o desenvolvimento de um sistema de consulta baseado em linguagem natural, especialmente diante do crescente interesse de cidadãos e profissionais em compreender seus direitos sem necessariamente recorrer a um advogado. Uma abordagem tecnológica projetada para mitigar o problema da alucinação é a Geração com Recuperação Aumentada (*RAG*, do inglês *Retrieval-Augmented Generation*), proposta por Lewis et al. (2020).

Nessa arquitetura, o modelo de linguagem não responde exclusivamente a partir do conhecimento paramétrico adquirido no treinamento; em vez disso, o sistema recupera, em tempo de inferência, trechos relevantes de uma base documental previamente indexada em representações vetoriais e os disponibiliza como contexto para a geração da resposta. Isso permite que as respostas sejam diretamente fundamentadas nos documentos fornecidos, com possibilidade de citar a passagem ou o artigo exato utilizado, tornando o resultado rastreável e reduzindo o espaço para alucinação. A avaliação de sistemas *RAG* apresenta desafios próprios, por envolver múltiplas dimensões: a capacidade de recuperação dos trechos mais relevantes, a fidelidade da geração ao contexto recuperado e a qualidade da resposta final. Es

et al. (2024) propõem o *framework RAGAS (Retrieval Augmented Generation Assessment)*, que oferece métricas de avaliação sem necessidade de anotações manuais de referência, incluindo fidelidade (*faithfulness*), relevância da resposta e precisão do contexto.

Essas métricas serão adotadas como suporte metodológico para a avaliação do protótipo, complementadas por um conjunto-ouro de perguntas e respostas elaborado com base no texto do CDC é aplicado tanto ao protótipo com *RAG* quanto ao *baseline* sem *RAG*, utilizando o mesmo modelo nas duas condições.

2 PERGUNTA DE PESQUISA

Em que medida a arquitetura *RAG* reduz a taxa de alucinação e melhora a precisão de citação em consultas ao Código de Defesa do Consumidor (CDC), em comparação ao mesmo modelo de linguagem, utilizado sem mecanismo de recuperação?

3 HIPÓTESE (se aplicável)

Um chatbot desenvolvido com arquitetura *RAG*, que restringe a geração de respostas ao conteúdo indexado do Código de Defesa do Consumidor e exige a citação explícita do(s) artigo(s)-fonte, apresentará menor taxa de alucinação — definida como a proporção de respostas que citam artigos inexistentes ou atribuem conteúdo incorreto a artigos reais — e maior precisão de citação — definida como a proporção de respostas em que o artigo citado coincide com o gabarito do conjunto-ouro — em comparação ao mesmo modelo utilizado sem mecanismo de recuperação, sob as mesmas condições de temperatura e template de prompt.

4 JUSTIFICATIVA

A presente pesquisa justifica-se pela necessidade de mitigar o problema das alucinações em Modelos de Linguagem de Grande Escala (*LLMs*), especialmente em contextos jurídicos onde a precisão factual é crítica. Dado que o Código de Defesa do Consumidor (CDC) é um instrumento fundamental para a cidadania brasileira e possui um corpo textual delimitado, a aplicação da arquitetura *RAG (Retrieval-Augmented Generation)* surge como uma solução viável. Esta abordagem permite fundamentar as respostas em fontes verificáveis, reduzindo o risco de desinformação e fornecendo uma ferramenta rastreável para consulta pública e profissional.

5 OBJETIVO GERAL

Desenvolver um protótipo de chatbot baseado em arquitetura *RAG* que responda perguntas sobre o Código de Defesa do Consumidor de forma fundamentada, rastreável e com menor taxa de alucinação do que o mesmo modelo de linguagem, utilizado sem mecanismo de recuperação.

5.1 Objetivos específicos (se aplicável)

- Planejar o sistema através da definição do corpus do CDC, estratégia de segmentação de texto e elaborar um conjunto-ouro de perguntas e respostas para avaliação;
- Construir o pipeline *RAG*, realizar a indexação vetorial e implementar a condição *baseline* (sem recuperação) sob as mesmas configurações de modelo;
- Testar e comparar o desempenho das duas condições por meio da aplicação do conjunto-ouro e coletar métricas de alucinação e fidelidade.

6 MÉTODO PRELIMINAR

O método empregado é a pesquisa de desenvolvimento experimental, com entrega no formato de relatório técnico.

- Descrição da tecnologia: será desenvolvido um protótipo de chatbot com arquitetura *RAG* sobre o texto do Código de Defesa do Consumidor. O sistema realizará a indexação vetorial do CDC, recuperará os trechos mais relevantes a cada pergunta e gerará respostas em linguagem natural restritas ao conteúdo recuperado, com citação obrigatória do artigo-fonte. Quando a pergunta não encontrar fundamentação no CDC, o sistema responderá explicitamente que a informação não consta na lei.
- Definição dos modelos de *LLMs*: Qwen 2.5
- Definição das tecnologias utilizadas: O projeto utiliza *Python* como linguagem de programação e *GitHub* para versionamento do código. O pipeline *RAG* é orquestrado com *LangChain*, utilizando *Docling* para extração de texto dos *PDFs*, *Sentence Transformers* para geração de *embeddings*, e *RAGAS* para avaliação do sistema. O armazenamento é feito no *PostgreSQL*, com a extensão *pgvector* atuando como banco vetorial. A interface web é construída com *Streamlit* e o modelo de linguagem utilizado é o *Qwen 2.5*.

- Procedimentos metodológicos: o desenvolvimento seguirá três fases — planejamento (definição do corpus, estratégia de segmentação, elaboração do conjunto-ouro e configuração do modelo), construção (implementação do pipeline *RAG* e da condição *baseline* com o mesmo modelo sem recuperação) e testes (aplicação do conjunto-ouro e coleta de resultados). As duas condições — com *RAG* e sem *RAG* — utilizarão o mesmo modelo, a mesma temperatura e o mesmo template de prompt, de modo que a presença ou ausência do mecanismo de recuperação seja a única variável independente.
- Testes e resultados: o protótipo será avaliado por meio de um conjunto-ouro de aproximadamente 30 a 50 perguntas, organizadas em categorias de direito expreso, implícito, fora do escopo e interpretações múltiplas. As métricas coletadas serão: Taxa de alucinação, Precisão de citação, Taxa de recusa correta e Fidelidade ao contexto (*RAGAS faithfulness*). Os resultados serão comparados por um profissional da área para verificar a confirmação da hipótese.

Espera-se que a implementação da arquitetura *RAG* resulte em uma redução significativa na taxa de alucinação em comparação ao modelo *baseline*. Especificamente, prevê-se uma maior precisão de citação, onde as referências aos artigos do CDC correspondam fielmente ao gabarito do conjunto-ouro. Além disso, espera-se que o sistema demonstre alta fidelidade ao contexto (*faithfulness*), recusando-se a responder perguntas fora do escopo legal do CDC e garantindo que as informações geradas sejam estritamente fundamentadas nos trechos recuperados da legislação.

Listar as atividades a serem executadas semanalmente, considerando os prazos estabelecidos no Cronograma do TCC para cada *etapa*. Este exemplo de cronograma deve ser ajustado conforme o método escolhido.

Preenchimento do documento de ideação	X	X														
Avaliação de gate		X														
Stage 2																
Preenchimento do documento de planejamento			X	X												
Levantamento de métodos preliminar			X	X												
Avaliação de gate				X												
Stage 3																
Preparação e tratamento do CDC				X	X											
Implementação da indexação vetorial				X	X											
Desenvolvimento do pipeline RAG					X	X										
Avaliação de gate						X										
Integração do chatbot e interface de consulta						X	X									
Stage 4																
Testes funcionais e ajustes do sistema							X	X								
Avaliação de gate								X								

<i>Stage 5</i>															
Análise dos resultados								X	X						
Redação do relatório técnico									X	X					
Revisão final e ajustes									X	X					
Avaliação de gate										X					
<i>Stage 6</i>															
Preparação da apresentação/defesa														X	
Defesa/entrega final															X

REFERÊNCIAS

BRASIL. Lei n. 8.078, de 11 de setembro de 1990. Dispõe sobre a proteção do consumidor e dá outras providências. Brasília, DF: Presidência da República, 1990. Disponível em: <https://www.planalto.gov.br/ccivil_03/leis/18078compilado.htm>. Acesso em: 11 jun. 2026.

CONSULTOR JURÍDICO. Jusbrasil lança ferramenta de IA para auxiliar advogados e juízes. [S. l.], 19 mar. 2025. Disponível em: <<https://www.conjur.com.br/2025-mar-19/jusbrasil-lanca-ferramenta-de-ia-para-auxiliar-o-trabalho-de-advogados-e-juizes/>>. Acesso em: 11 jun. 2026.

DAHL, Matthew et al. Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models. *Journal of Legal Analysis*, [S. l.], v. 16, n. 1, p. 64-93, 2024. Disponível em: <<https://academic.oup.com/jla/article/16/1/64/7699227>>. Acesso em: 11 jun. 2026.

ES, Shahul et al. RAGAs: Automated Evaluation of Retrieval Augmented Generation. In: CONFERENCE OF THE EUROPEAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 18., 2024, St. Julians. Anais [...]. St. Julians:

Association for Computational Linguistics, 2024. p. 150-158. Disponível em: <<https://aclanthology.org/2024.eacl-demo.16/>>. Acesso em: 11 jun. 2026.

LEWIS, Patrick et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020. Anais [...]. [S. l.]: Curran Associates, 2020. p. 9459-9474. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>. Acesso em: 11 jun. 2026.

PIRES, Ramon et al. Sabiá: Portuguese Large Language Models. In: BRAZILIAN CONFERENCE ON INTELLIGENT SYSTEMS (BRACIS), 12., 2023, Belo Horizonte. Anais [...]. Cham: Springer Nature Switzerland, 2023. p. 226-240. ISBN 978-3-031-45392-2. Disponível em: <<https://arxiv.org/abs/2304.07880>>. Acesso em: 11 jun. 2026.



OKCIT

CENTRO DE COMPETÊNCIA EMBRAPII
EM TECNOLOGIAS IMERSIVAS



MINISTÉRIO DA
CIÊNCIA, TECNOLOGIA
E INOVAÇÃO

